

第七組 期末書面報告

OptETF

偏好驅動之智能 ETF 資產配置系統

課程：金融科技

組員：

110011131 蔡妮軒

111034010 羅彥凱

111034058 林昱佑

114071507 張立妍

摘要

OptETF 是一套結合作業研究（Operations Research）與金融科技（FinTech）的決策支援框架，以使用者偏好為核心驅動，自動建構個人化 ETF 投資組合。系統採用五階段模組化管線：Stage 0 市場資料特徵工程、Stage 1 DEA 效率篩選、Stage 2_1 雙路徑偏好萃取、Stage 2_2 相關性去重分群，以及 Stage 3 偏好驅動之 SLSQP 最佳化。

系統在 2019–2026 年約七年的樣本外測試中，七種使用者原型的投組在偏好滿足度上均勝過 VT 全球市場基準（勝率 89–100%）。其中報酬導向型（採 beta 核心）的年化報酬穩定達 16.40–17.58%，優於 VT 基準的 14.32%。

關鍵詞：ETF 篩選、偏好驅動最佳化、DEA、Black-Litterman 模型、貝氏類神經網路（BNN）、Ledoit-Wolf 共變異數縮減、Walk-Forward 驗證

一、研究動機與背景

1.1 問題背景

台灣與全球 ETF 市場近年高速成長，可投資標的已達數千檔，涵蓋股票、債券、主題型、槓桿/反向等多種類型。散戶投資者面臨兩大核心困境：

- 資訊不對稱：面對海量 ETF 難以有效篩選，缺乏客觀的多維效率評估工具
- 偏好量化困難：個人風險偏好、報酬期望往往停留在主觀描述，無法直接轉換為最佳化配置決策

傳統 Robo-Advisor 產品的兩大缺陷在於：（1）忽視 ETF 市場的多維效率關係，未對標的進行客觀篩選；（2）偏好擷取方法過於靜態或不透明，難以反映投資者的真實決策邏輯。

1.2 研究動機：現有方法的侷限

Markowitz 均值-變異數模型雖理論嚴謹，但對預期報酬輸入高度敏感——樣本期望報酬的估計噪音會被最佳化器放大，導致「錯誤最佳化（error maximization）」問題。Black-Litterman 模型雖引入主觀觀點以錨定市場先驗，但仍需投資者將模糊偏好手動量化為精確觀點向量，門檻極高。

同時亦有幾項對報酬預測失準與傳統問卷的洞察：

- 報酬預測的天花板：散點分析顯示過去 CAGR 對未來 CAGR 的預測能力近於零（ $r \approx 0$ ），應改以系統性風險（beta）作為報酬維度的代理指標
- 偏好萃取的多元性：不同使用者對互動介面的接受度差異顯著，應同時提供靜態問卷、自然語言對話兩條路徑

- 效率篩選的必要性：在最佳化前先透過 DEA 剔除「投入多、產出少」的低效 ETF，可顯著提升候選池品質，減少最佳化過程中的雜訊

1.3 研究目標

OptETF 的具體設計目標如下：

- 客觀篩選：以 DEA 兩階段效率分析建立與主觀偏好解耦的 ETF 候選池
- 多元偏好萃取：以靜態 AHP 問卷與 BNN 自然語言偏好引擎兩條主要路徑（另有 Gemini 主動式訪談為實驗性／未來工作）統一輸出九維偏好向量
- 穩健最佳化：結合 Ledoit-Wolf 共變異數縮減與偏好驅動的 SLSQP 求解，降低估計誤差
- 三核心架構（U-C2）：以連續映射函式 $g(w)$ 將九維偏好向量對應至 minvar / market / beta 三個效率前沿位置
- 嚴謹驗證：採用 Walk-Forward 滾動視窗驗證，全程禁止未來資料洩漏
- 互動前端：提供 Web 問卷介面，即時呈現投資組合分析結果

二、方法論

2.1 系統整體架構

OptETF 採用五階段模組化管線設計（表 2.1），各階段職責分明、可獨立升級，全部透過 `pipeline_stages.py` 統一調度，以 `main.py` 為入口：

階段	模組	核心功能
Stage 0	市場資料工程	透過 YahooQuery / Alpha Vantage / Finnhub 擷取 ETF 特徵；本地 FinBERT 時間衰減情緒評分；Robust Scaling 正規化，輸出 DEA 前特徵矩陣
Stage 1	DEA 效率篩選	兩階段 DEA（CCR 標準效率 → 交互效率）篩選前 25% 效率分位，輸出解耦於偏好的候選池
Stage 2_1	偏好萃取（雙路徑）	靜態 AHP 問卷與 BNN 自然語言偏好引擎兩條主要路徑（Web 介面為 BNN 引擎之前端；Gemini 主動式訪談為實驗性／未來工作），統一輸出九維偏好向量（JSON）
Stage 2_2	相關性去重分群	依偏好向量對 ETF 進行相關性分群，每群選出最符合偏好的代表標的，降低投組集中風險
Stage 3	SLSQP 最佳化	偏好 → 參數映射 $g(w)$ 選定 U-C2 核心，Ledoit-Wolf 縮減共變異數矩陣，SLSQP 求解帶約束投組；含選擇性 Walk-Forward 回測（Stage 3B）

表 2.1 OptETF 五階段管線總覽

2.2 資料擷取與特徵工程 (Stage 0)

系統整合三大資料源，建構多維 ETF 特徵矩陣：

- YahooQuery (yfinance)：ETF 每日收盤價、成交量、股息殖利率、費用率
- Alpha Vantage：歷史基本面數據（本益比、市值、機構持股比例）
- Finnhub：即時新聞與市場情緒流，供 FinBERT 情緒分析使用

情緒分析採本地部署的 FinBERT 模型，對財經新聞輸出 $[-1, 1]$ 情緒分數，並施加時間衰減加權——近期新聞賦予較高權重，反映市場情緒的時效性。特徵正規化採縮尾 min-max (robust_scale)：先以分位數 $[Q_{0.01}, Q_{0.95}]$ 縮尾，再線性壓縮至 $[0, 1]$ ，對金融時序的厚尾極端值具強魯棒性（風險／成本維度取 $1 - \text{norm}$ ，使數值越低者得分越高）：

$$\text{norm}(x) = (\text{clip}(x; Q_{0.01}, Q_{0.95}) - x_{\min}) / (x_{\max} - x_{\min})$$

2.3 DEA 兩階段效率篩選 (Stage 1)

資料包絡分析 (Data Envelopment Analysis, DEA) 以非參數方式評估各 ETF 的相對效率，優點在於無需指定生產函數形式，且完全基於客觀數據，與使用者偏好解耦。

2.3.1 第一階段：CCR 標準效率

採輸入導向 CCR 模型 (Constant Returns to Scale)，求解各 ETF 的效率分數 θ ：

$$\begin{aligned} \max \theta_0 &= \frac{u \cdot y_0}{v \cdot x_0} \\ \text{s.t. } \frac{u \cdot y_j}{v \cdot x_j} &\leq 1, \forall j ; u, v \geq 0 \end{aligned}$$

其中投入指標 (x) 包含費用率、年化波動度、最大回撤；產出指標 (y) 包含資本利得 (Out_CAGR)、股息殖利率 (Out_Div)、流動性 (Out_Liquidity)、多角化程度 (Out_Diversity) ——資本利得與股息刻意拆成兩個獨立產出，避免高成長零股息 ETF 被股息平均稀釋。 $\theta = 1$ 表示位於效率前沿。

2.3.2 第二階段：交互效率 (Cross-Efficiency)

交互效率矩陣解決 CCR 結果中多個 DMU 同時達到 $\theta = 1$ 的鑑別力不足問題。以每個 ETF 在自身最優權重下評估所有其他 ETF，建構 $n \times n$ 矩陣，取列均值作為最終效率排名分數。最終保留前 25% 效率分位的 ETF 進入偏好萃取階段。

2.4 兩路徑偏好萃取 (Stage 2_1)

系統的核心設計亮點在於兩條平行偏好路徑（靜態 AHP 問卷與 BNN 自然語言偏好引擎）統一輸出至相同介面，後續最佳化無需改寫；另提供一條實驗性的 Gemini 主動式自然語言訪談（列為未來工作）。九個偏好維度涵蓋：資本增值

（CAGR 代理）、股息殖利率、波動穩定性、最大回撤韌性、費用率、交易量、基金規模、多角化程度、市場情緒。

2.4.1 靜態 AHP 問卷 (Static AHP)

以分析層級程序法 (Analytic Hierarchy Process) 透過成對比較矩陣量化使用者對九個維度的相對重視程度。系統採用兩層 AHP 架構：先對大類（報酬、風險、成本、流動性、情緒）進行比較，再對大類內的子維度比較，最後整合為九維優先向量。一致性檢驗確保 $CR < 0.1$ ：

$$A \cdot w = \lambda_{max} \cdot w$$

$$CI = \frac{(\lambda_{max} - n)}{(n - 1)}, CR = \frac{CI}{RI} < 0.10$$

2.4.2 Active Bayesian LLM 訪談 (實驗性／未來工作)

（本路徑為實驗性，目前以可選模組形式存在於 active_preference 套件、尚未整合為主要交付路徑，故列為未來工作；前述兩條主要路徑為靜態 AHP 與 BNN 偏好引擎。）整合 Gemini LLM 作為自然語言偏好訪談代理，透過六個微階段（初始化 → 選定目標維度 → 提問 → 擷取證據 → 更新信念 → 匯出權重）逐步精煉使用者偏好。每輪對話後以貝氏更新調整 Dirichlet 後驗分佈：

$$P(w|data) \propto P(data|w) \cdot P(w)$$

LLM 負責將模糊的口語描述（如「我希望收益穩定，不怕少賺但要少賠」）轉換為結構化的偏好置信度更新，最終輸出與靜態 AHP 相同格式的九維權重向量。

2.4.3 BNN 偏好引擎 (Preference Engine)

本路徑採用投資理念描述 (philosophy input) 加上逐輪問答的深度學習方案。BGE-M3 多語言向量模型將使用者文字描述嵌入為語義向量，輸入 9 個各維一維貝氏類神經網路 (Bayesian Neural Network，每個偏好維度各一個，外加一個理念向量頭 philhead，共 10 個 .pt 權重檔)；不確定性由 MC-dropout 多次取樣估計（非模型集成），輸出九維偏好向量的均值與信心區間：

$$\mu_w, \sigma_w^2 = \text{BNN_ensemble}(\text{BGE-M3}(\text{query}))$$

BNN 的不確定性輸出 σ^2_w 用於偏好問答過程的即時回饋與收斂／穩定性判斷；系統最佳化採 μ -free 的三核心 C2，並不把 σ^2 送入 Black-Litterman 的觀點不確定性矩陣 Ω （將 σ^2 接入統一 BL 的構想經 A/B 測試後未採用，詳見成果報告 §3.3）。

2.5 相關性去重分群 (Stage 2_2)

DEA 候選池內的 ETF 可能存在高度相關性（如同類型的 S&P 500 ETF），若直接最佳化易導致集中於相關資產。Stage 2_2 依相關性矩陣對候選 ETF 進行分群，每群選出與使用者九維偏好點積最高的代表標的，確保最終候選池的多角化品質。

2.6 偏好驅動最佳化：U-C2 三核心模型（Stage 3）

2.6.1 偏好→參數連續映射 $g(w)$

系統最重要的設計決策是採用「連續映射函式 $g(w)$ 」而非查表法，將九維偏好向量轉換為最佳化參數。核心切換指數 T_growth 由報酬類偏好權重比例決定：

$$T_{growth} = \frac{w_{CAGR}}{w_{CAGR} + w_{vol} + w_{mdd}}$$

根據 T_growth 連續映射至三個效率前沿位置：

T_growth 區間	核心模式	目標函數	投資人屬性
< 0.40	minvar （保守）	$\min w^T \Sigma w$	退休族、高波動厭惡
$0.40 - 0.65$	market （均衡）	track market ($\beta \approx 1$)	長期指數投資人
≥ 0.65	beta （積極）	$\max \beta$ within budget	積極成長、高風險承受

表 2.2 U-C2 三核心模型對應關係

映射函式同時決定風險分數（ $risk_fraction$ ）、波動預算（ vol_budget ，於候選池可行波動範圍內線性內插， v_min/v_max 為候選池最小／最大變異組合波動，故恆可行）及 τ （股息傾斜強度，高成長偏好者獲低 τ 、以 **beta** 為主；收息導向者獲高 τ ）。此設計確保任意使用者偏好向量均可無縫進入同一最佳化管線。

$$risk_fraction = \text{clip}(T_growth, 0.05, 0.95)$$

$$vol_budget = v_min + risk_fraction \cdot (v_max - v_min)$$

$$\tau = 0.3 \cdot (1 - T_growth) \cdot \hat{R}$$

2.6.2 三核心 C2 的 SLSQP 求解（Black-Litterman／CAPM 為理論地基）

系統最佳化採 μ -free 的 U-C2 三核心：完全不估計樣本期望報酬 μ ，從根本避開估計誤差被最佳化器放大的問題（ $1/N$ 之謎）。其理論地基為 Black-Litterman／CAPM——市場均衡隱含報酬 $\Pi = \lambda \Sigma w_mkt \propto \beta$ （CAPM），故三核心恰為 BL 效率前緣上不同風險趨避的點。下式為 Black-Litterman 的一般後驗報酬形式（混合均衡 Π 與觀點 P 、 Q 、不確定性 Ω ），僅作為理論對照；本系統並不組裝 $P/Q/\Omega$ 、也不以此後驗作為求解輸入，而是依 $g(w)$ 選定的核心直接求解（見後）。注意：此一般式中的 τ 為 BL 先驗不確定性純量，與後文三核心目標式中的偏好傾斜強度 τ 為不同用途。

$$E[R] = [(\tau \Sigma)^{-1} + P^T \Omega^{-1} P]^{-1} \cdot [(\tau \Sigma)^{-1} \Pi + P^T \Omega^{-1} Q]$$

共變異數矩陣採 Ledoit-Wolf 縮減（sklearn 之 LedoitWolf 估計器，依資料自動決定最優縮減強度 δ^* ）：

$$\Sigma_{LW} = (1 - \delta) \cdot S + \delta \cdot \mu I, \quad \mu = \text{tr}(S) / p$$

最終以 SLSQP 求解帶約束最佳化。三個核心的目標式皆為 μ -free，且都含偏好傾

斜項 $-\tau \cdot w^T s$ (s 為九維偏好分數向量、 τ 為偏好傾斜強度)；其中 Σ 為 Ledoit-Wolf 收縮共變異、 $c = \text{Cov}(r, r_{VT})$ (對 VT 之共變異)、 $\beta = c / \text{Var}(r_{VT})$ (系統性風險曝險)、 $cap = 0.40$ ：

$$\text{minvar} : \min_w \frac{1}{2} \cdot w^T \Sigma w - \tau \cdot w^T s$$

$$\text{market} : \min_w \frac{1}{2} \cdot w^T \Sigma w - w^T c - \tau \cdot w^T s$$

$$\text{beta} : \max_w w^T \beta + \tau \cdot w^T s$$

$$\text{s.t. } 1^T w = 1, \quad 0 \leq w_i \leq cap = 0.40, \quad \sqrt{(w^T \Sigma w)} \leq vol_budget$$

系統另建有品質硬約束框架(費用率上限、HHI 集中度、流動性門檻、情緒分數)，但 OAT 一次開一個的消融實驗顯示其無益(成本約束一旦咬到即傷 Sharpe / win_VT，HHI 與流動性則完全 inert，因投組本已夠分散、夠低成本)，故現預設全部關閉(QC_ENABLE_* = False)；品質改由軟偏好傾斜+DEA 篩選+核心類型處理(奧坎剃刀，詳見成果報告 §3.4)。

2.7 Web 前端介面

系統提供 Flask 架構的 Web 應用(etf_web/app.py)，支援從瀏覽器完成完整分析流程：

- 偏好輸入：使用者透過結構化問卷或自然語言對話輸入偏好，系統追蹤回答信心度，對矛盾偏好發出釐清請求
- 管線執行：後台非同步執行五階段管線(含可選資料重抓與回測)，前端以 polling 追蹤進度
- 結果呈現：互動式雷達圖(九維偏好 vs 投組特徵)、投資組合圓餅圖、績效走勢圖表、vs 基準比較(VT / VOO)
- 報告下載：自動生成文字版投資分析報告與回測摘要，支援下載

三、驗證設計

3.1 Walk-Forward 滾動視窗驗證

為確保策略的實際可部署性，OptETF 採用 Walk-Forward Validation 作為核心驗證框架，每個再平衡日僅使用該日期以前的歷史資料，嚴格禁止未來資訊洩漏(Look-Ahead Bias)。

驗證設定：2016–2026 年共約十年數據(最低歷史需求 8 年)，回望視窗 3 年，支援月(M)、季(Q)、半年(6M)、年(Y)四種再平衡頻率。每個再平衡日的執行流程：

- 在回望視窗內計算特徵矩陣(報酬、波動度、Sharpe 比率、情緒分數)
- 執行 DEA 篩選(前 25% 效率分位)，取得候選 ETF

- 套用當前偏好向量執行 Stage 2_2 → Stage 3 最佳化
- 持有至下一再平衡日，累積股息與資本利得分開追蹤

3.2 七種使用者原型測試

系統預設七種使用者原型（User Profiles），涵蓋從極度保守到高度積極的偏好分布，作為系統性驗證的標準測試集：

原型名稱	偏好描述	對應核心
aggressive_growth	最大化長期資本增值，忽略短期波動	beta
return_leaning	追求報酬但接受一定風險管理	beta
balanced	均衡報酬與風險，長期穩定增長	market
conservative	資本保全優先，最低波動	minvar
income	高股息殖利率為主要目標	minvar（高 τ 股息偏斜）
cost_liquidity	低費用率 + 高流動性	market
diversified_quality	多角化 + 高品質篩選	market

表 3.1 七種標準使用者原型

profile	報酬CAGR	殖利率	抗波動	抗回撤	低成本	交易量	資產規模	產業分散	情緒
aggressive_growth	0.55	0.00	0.05	0.05	0.05	0.05	0.05	0.10	0.10
return_leaning	0.40	0.10	0.14	0.06	0.10	0.04	0.04	0.07	0.05
balanced	0.22	0.13	0.15	0.12	0.10	0.05	0.05	0.13	0.05
conservative	0.08	0.12	0.28	0.22	0.10	0.04	0.06	0.08	0.02
income	0.10	0.40	0.12	0.10	0.10	0.03	0.05	0.08	0.02
cost_liquidity	0.18	0.10	0.12	0.08	0.22	0.12	0.10	0.06	0.02
diversified_quality	0.15	0.10	0.12	0.10	0.08	0.04	0.06	0.20	0.15

表 3.2 七種標準使用者真實權重

profile	T_growth（資本利得渴望）	核心 core	risk_fraction	τ （傾斜強度）
aggressive_growth	0.85	beta	0.85	0.025
return_leaning	0.67	beta	0.67	0.050
cost_liquidity	0.47	market	0.47	0.044
balanced	0.45	market	0.45	0.058
diversified_quality	0.41	market	0.41	0.045
income	0.31	minvar	0.31	0.103
conservative	0.14	minvar	0.14	0.052

表 3.3 七種標準使用者報酬與風險偏好映射

3.3 績效評估指標

各再平衡期計算以下績效指標，並跨期加權平均：

- 年化報酬率（CAGR）：資本利得與股息分開計算後合併
- 年化波動度（Annualized Volatility）
- Sharpe 比率（Risk-Free Rate 以當期短期國債利率為準）
- 最大回撤（MDD）：同時提供代理值與真實值兩種計算
- Calmar 比率 = CAGR / |MDD|
- Turnover Rate：換手率，評估交易成本影響(本系統將換手摩擦設定為 0)
- 偏好滿足度分數：九維投組特徵與使用者偏好向量的加權點積

3.4 樣本外驗證結果

以下為 2019–2026 年樣本外測試的核心結果摘要（季度再平衡，回望視窗 3 年），基準為 VT 全球市場 ETF：

profile	core	CAGR%	Sharpe	Vol%	MaxDD%	殖利率%	成交量(M)	AUM(B)	費用率%	產業HHI	win_VT%
aggressive_growth	beta	17.58	0.675	21.59	-33.33	1.17	5.6	66.5	0.049	0.213	100
return_leaning	beta	16.40	0.668	19.74	-33.46	1.78	6.3	126.2	0.046	0.173	89.3
balanced	market	12.71	0.563	16.71	-36.13	3.33	6.7	95.4	0.054	0.124	100
conservative	minvar	9.70	0.447	14.02	-35.15	3.55	5.3	18.2	0.267	0.209	96.4
income	minvar	11.94	0.545	15.68	-38.45	4.83	6.6	52.1	0.152	0.138	100
cost_liquidity	market	14.12	0.630	16.96	-33.08	2.80	11.0	290.3	0.043	0.125	100
diversified_quality	market	12.67	0.564	16.55	-33.97	3.15	6.3	94.6	0.057	0.124	100
VT (基準)	—	14.32	0.606	18.30	-33.72	1.82	2.1	76.0	0.060	0.167	—

表 3.4 各原型樣本外績效摘要（2019–2026，季度再平衡）

偏好勝率定義為：在所有再平衡測試期中，OptETF 投組的偏好滿足度分數高於 VT 基準的比例。結果顯示系統在「滿足使用者偏好」層面具高度一致性，符合「決策支援工具」而非「追求絕對報酬」的定位。

3.5 結果分析

綜合表 3.2 與七種原型的逐維度實測（完整對照見 user_results/showcase_7_profiles/對照分析報告.md），可歸納以下重點：

（1）只有 beta 核心（報酬導向）真正贏過 VT 的「絕對報酬」。
aggressive_growth（CAGR 17.58%）與 return_leaning（16.40%）是七人中唯二 CAGR 高於 VT（14.32%）者，且 Sharpe（0.675／0.668）亦高於 VT（0.606），代價是更高波動（21.59%／19.74% vs 18.30%）。
aggressive_growth 的 risk_fraction（0.85）高於 return_leaning（0.67），以更高波動換更高報酬，「風險→報酬」階梯乾淨。此即 U-C2 的存在理由：報酬不來自預測個股，而來自承擔更多系統性風險（beta）。

(2) market/minvar 核心換到的是「風險效率」與「偏好滿足」，而非絕對報酬。balanced、cost_liquidity、diversified_quality、income、conservative 的 CAGR 皆低於 VT，但波動全部低於 VT (14–17% vs 18.30%)；其中 cost_liquidity 的 Sharpe (0.630) 甚至高於 VT，conservative 波動最低 (14.02%)。這是系統誠實的定位——不是打敗市場報酬，而是更安全、更貼合偏好。

(3) 每個原型都在自己最重視的維度上明顯勝出（「招牌」被滿足），如表 3.3。例如 income 的平均殖利率 4.83% (VT 的 2.7 倍、全場最高)，累積股息報酬 39.4% vs VT 18.3%；cost_liquidity 費用率 0.043% 全場最低、成交量 11.0M 與 AUM 290B 全場最高；diversified_quality 與 balanced 產業 HHI 0.124 最分散；conservative 波動 14.02% 最低。反向亦佐證誠實性：每個原型在「自己不在意」的維度上就較弱（如 aggressive_growth 殖利率僅 1.17%、conservative 費用率偏高 0.267%），說明系統是依偏好取捨，而非全維度通吃。

原型	核心	最重視維度	實測值	VT 對照	結果
aggressive_growth	beta	資本增值	CAGR 17.58%	14.32%	全場最高、贏 VT
return_leaning	beta	資本增值	CAGR 16.40%	14.32%	贏 VT
income	minvar	股息殖利率	4.83%	1.82%	全場最高 (2.7 倍)
cost_liquidity	market	低費用／流動性	費用 0.043%；量 11.0M	0.060%；2.1M	費最低、量最高
diversified_quality	market	產業分散 (HHI)	0.124	0.167	最分散
conservative	minvar	抗波動	波動 14.02%	18.30%	全場最低
balanced	market	各維均衡	無明顯短板	—	均衡

表 3.5 各原型在自身招牌維度的滿足度 (回溯期平均，vs VT)

(4) 對三個對照組全面領先偏好分數。七人對 VT 的偏好勝率 89–100%、對 EqualWeight 93–100%、對 MaxSharpe 89–100%——在「滿足使用者偏好」上穩定勝過 VT、等權與最大夏普。

(5) 兩個誠實的張力（不掩飾）。其一，return_leaning 的 win_VT 為七人最低 (89.3%，仍高)：它同時要高報酬 (40%) 又要抗波動，是自我矛盾的偏好，其集中型高 beta 投組在 VT 強勢的結構維度（成本／分散／流動性）失分較多，但仍以絕對報酬大勝、贏 VT 近九成期數。其二，部分防禦型原型的 MaxDD 反比 VT 深 (income -38.45%、balanced -36.13%、conservative -35.15% vs VT -33.72%)，印證「壓低波動 ≠ 控制回撤」（兩者為不同風險測度）；真正控回撤需加 MaxDD 約束（列為未來工作）。

(6) g(w) 行為正確。T_growth 由 0.85 (aggressive_growth) 連續降到 0.14

(conservative)，核心自動 $\beta \rightarrow \text{market} \rightarrow \text{minvar}$ 、 risk_fraction 同步遞減， income 自動取得最高 τ (0.103) 做股息傾斜。整條映射是偏好權重的連續函數，AHP 任意權重與這七個手設原型走同一條路徑。

四、開發限制

4.1 資料層面限制

- 地理範圍侷限：系統目前僅覆蓋美國 ETF 市場 (2016–2026 期間)，產業分布回溯採當前快照反向套用至歷史，存在輕微 Look-Ahead Bias
- API 限制：Alpha Vantage 免費版每日 API 調用上限為 25 次，大規模即時更新受限；Finnhub 存在 15–20 分鐘資料延遲，不支援日內策略
- FinBERT 語料偏差：預訓練 FinBERT 以英文財經新聞為主，情緒分數在非英語市場具系統性偏差
- 數據深度：部分新發行 ETF 的歷史數據不足 3 年，無法完整參與 Walk-Forward 驗證

4.2 演算法層面限制

- 低波動異常：報酬導向型投組在低波動環境下 Sharpe 比率反而遞減，顯示 β 核心在特定市場環境下的局限性
- BNN 訓練資料：偏好引擎目前以合成偏好資料訓練，真實使用者偏好標註數據不足，泛化能力待驗證
- 波動約束侷限：波動預算 (VOL_BUDGET) 無法有效控制最大回撤，報酬導向型投組在熊市中的回撤深度仍顯著
- 單一市場假設：Black-Litterman 的市場均衡先驗 (CAPM) 假設市場效率；factor premiums 在不同地理市場的適用性不確定

4.3 設計權衡

- 偏好分數非 α 來源：系統目標是「偏好滿足」而非「市場超額報酬」，兩者並不等價，部分使用者可能對此存在混淆
- τ 強度綁定：目前 τ (偏好傾斜強度) 與 T_{growth} 掛鉤，可能低估非報酬維度 (如 ESG、流動性) 的偏好強度
- 交易成本未納入：SLSQP 每期重新最佳化未考量實際交易成本與稅務，真實部署需加入換倉懲罰項
- 容器化尚未完成：目前缺乏 Dockerfile，部署環境複製依賴手動 pip 安裝，環境一致性風險存在

五、未來展望

5.1 近期優先改善（已識別）

開發團隊在 README 與 REPORT_B 中明確列舉了按優先順序排列的改善路線：

- 安全性強化：API Key 全面移至 .env 環境變數，避免金鑰硬編碼至原始碼
- 測試覆蓋：新增 tests/ 單元測試（DEA 求解器、AHP 一致性、最佳化器邊界條件）
- 日誌系統：統一改用 Python logging 模組，替換現有 print 輸出，支援日誌分級與持久化
- Docker 容器化：提供 Dockerfile 與 docker-compose.yml，實現一鍵部署與環境隔離
- 版本控制輸出：為 report/、png/、backtest/ 輸出檔案加入時間戳記或整合 DVC（Data Version Control）

5.2 演算法升級方向

- 因子觀點整合：在 Black-Litterman 框架下納入 Fama-French 多因子模型，以系統因子暴露（size、value、momentum）作為觀點 P 矩陣的結構化先驗，取代純偏好映射
- 歷史逐期產業快照：建立「各時間點的產業分布快照」資料庫，消除現有回測中的產業分布 Look-Ahead Bias
- 直接 MaxDD 約束：研究將最大回撤直接納入 SLSQP 約束的方法（CVaR 代理或情境分析），解決波動預算無法控制極端損失的問題
- 強化學習動態再平衡：以 PPO/SAC 演算法取代固定頻率再平衡，讓智能體依市場狀態動態決定再平衡時機與幅度

5.3 產品化與跨市場擴展

- 跨市場驗證：擴展至台灣、歐洲、新興市場 ETF，驗證系統在不同市場結構下的適用性
- 真實除息事件：引入精確的除息日期資料（替換現有代理計算），提升股息追蹤的準確性
- ESG 整合：導入 MSCI ESG 評分或 Sustainalytics 資料作為 DEA 投入/產出維度，支援永續投資主題篩選
- 行動裝置整合：將 Web 問卷與結果報告整合至 LINE Bot 或原生 App，降低使用門檻
- 券商 API 串接：與富邦、元大等國內券商 API 整合，實現從「建議」到「執行」的全自動再平衡

六、結論

跨七種使用者原型的樣本外驗證顯示，OptETF 的系統行為與設計論述完全一致且誠實：

- 報酬導向使用者 → **beta** 核心 → 穩定贏過 VT 的絕對報酬（以承擔更多系統性風險換得：**aggressive_growth** 17.58%、**return_leaning** 16.40% vs VT 14.32%，且 **Sharpe** 亦較高）。
- 保守／收入／平衡／品質型 → **market**／**minvar** 核心 → 贏在更低波動、風險效率與偏好滿足，而非絕對報酬；每位使用者都在自己最重視的維度上明顯勝出（如 **income** 殖利率為 VT 的 2.7 倍、**cost_liquidity** 費用最低且流動性最高、**conservative** 波動最低）。
- 全體七原型的偏好滿足度勝率穩定高於 VT（89–100%），對等權與最大夏普亦達 89–100%——在「滿足使用者偏好」上對三個對照組全面領先。

本系統的價值在於：理論地基紮實（以 **Black-Litterman**／**CAPM** 支撐三核心，三核心即 **BL** 效率前緣上不同風險趨避的點）、偏好驅動且 **profile-dependent**、經跨市場規制的 **walk-forward** 驗證，並對自身限制誠實量化（偏好矛盾者勝率最低但仍高、防禦型 **MaxDD** 未必優於 VT、單一市場與單一歷史路徑）。

須強調系統定位：偏好滿足度為「偏好提取＋樣本外驗證」指標，並非 **alpha** 來源；系統不宣稱能穩定打敗市場的風險調整後報酬（**1/N** 之謎）。作為「依使用者偏好、在可承受風險內提供站得住腳之投組，並以樣本外證據說明它做到了什麼」的決策支援框架，OptETF 的結論站得住腳。

七、參考資料

- [1] Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77–91.
- [2] Sharpe, W. F. (1964). Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk (CAPM). *The Journal of Finance*, 19(3), 425–442.
- [3] Black, F., & Litterman, R. (1992). Global Portfolio Optimization. *Financial Analysts Journal*, 48(5), 28–43.
- [4] Charnes, A., Cooper, W. W., & Rhodes, E. (1978). Measuring the Efficiency of Decision Making Units (DEA/CCR). *European Journal of Operational Research*, 2(6), 429–444.
- [5] Ledoit, O., & Wolf, M. (2004). Honey, I Shrunk the Sample Covariance Matrix. *The Journal of Portfolio Management*, 30(4), 110–119.
- [6] DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy? *The Review of Financial Studies*, 22(5), 1915–1953.
- [7] Saaty, T. L. (1980). *The Analytic Hierarchy Process (AHP)*. McGraw-Hill.
- [8] Gal, Y., & Ghahramani, Z. (2016). Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning (MC-dropout). *ICML*.
- [9] BAAI (2024). BGE-M3: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings.
- [10] Araci, D. (2019). FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. *arXiv:1908.10063*.

專案原始碼（GitHub）：<https://github.com/JasonRott/FinTech-Project->

FinalVersion

結果重現：於專案根目錄執行 `ACTIVE_USER_PROFILE=<profile> python main.py`（七個原型鍵見 `parameters.USER_PROFILES`）；七原型完整對照見 `user_results/showcase_7_profiles/對照分析報告.md`。

附錄 A：核心數學推導

A.1 DEA 交互效率矩陣

標準 CCR-DEA 可能使多個 ETF 同時獲得 $\theta = 1$ （均位於前沿），無法進一步排名。交互效率矩陣 E 的第 (k, j) 元素定義為：以第 k 個 ETF 的最優權重 (u_k^*, v_k^*) 評估第 j 個 ETF 的效率值：

$$E_{kj} = \frac{u_k^* \cdot y_j}{v_k^* \cdot x_j}$$

最終效率分數取列均值： $\bar{\theta}_j = \frac{1}{n} \sum_k E_{kj}$ ，克服了 CCR 的鑑別力不足問題，並具有對所有 DMU 的統一公平性。

A.2 Black-Litterman 完整推導

市場均衡隱含超額報酬（CAPM 反推）：

$$\Pi = \lambda \cdot \Sigma \cdot w_{mkt}$$

其中 λ 為市場風險趨避係數（通常取 2-3）， w_{mkt} 為市場組合權重。混合後驗期望報酬：

$$E[R] = [(\tau\Sigma)^{-1} + P^T\Omega^{-1}P]^{-1} \cdot [(\tau\Sigma)^{-1}\Pi + P^T\Omega^{-1}Q]$$

上式為 Black-Litterman 一般形式（理論對照，非本系統實作）： P （ $k \times n$ 觀點矩陣）、 Q （ $k \times 1$ 觀點報酬）為觀點向量， Ω （ $k \times k$ 對角矩陣）的對角元素為各觀點的不確定性方差 σ_w^2 。後驗共變異數：

$$M = [(\tau\Sigma)^{-1} + P^T\Omega^{-1}P]^{-1}$$

系統文件中點出：最小化投組變異減對 VT 報酬追蹤誤差，等價於最大化 BL 隱含報酬減 $\lambda/2$ 倍風險，確保了 market 核心的理論一致性。

A.3 Ledoit-Wolf 最優縮減係數

Ledoit-Wolf 估計器（系統實際使用 `sklearn.covariance.LedoitWolf`）將樣本共變異 S 往球形目標 $F = \mu I$ 收縮（ $\mu = \text{平均變異} = \text{tr}(S)/p$ ），在 Frobenius 距離意義下求最優收縮強度 δ^* ：

$$\Sigma_{LW} = (1 - \delta) \cdot S + \delta \cdot F, F = \mu I, \mu = \text{tr}(S) / p$$

收縮強度 δ^* （由資料估計，Ledoit-Wolf 閉合式）：

$$\delta^* = \text{clip}(\hat{\pi} / \hat{\gamma}, 0, 1), \hat{\gamma} = \|S - F\|_F^2, \hat{\pi} = (1/T) \sum_t \|x_t x_t^T - S\|_F^2$$

其中 p 為資產數， T 為觀測期數。當 $T \gg p$ 時 $\alpha^* \rightarrow 0$ （無需縮減）；當 $T \approx p$ 時 $\alpha^* \rightarrow 1$ （強縮減至球形矩陣）。

A.4 偏好→參數映射 $g(w)$ 詳細邏輯

九維偏好向量 $W = (w_{CAGR}, w_{div}, w_{vol}, w_{mdd}, w_{cost}, w_{liq}, w_{size}, w_{div_hhi}, w_{sent})$ 的核心切換邏輯：

$$T_{growth} = \frac{w_{CAGR}}{w_{CAGR} + w_{vol} + w_{mdd}}$$

波動預算於候選池可行波動範圍內依 $risk_fraction$ 線性內插（ v_min/v_max 為當期候選池的最小／最大變異組合波動，並非固定常數）：

$$risk_fraction = clip(T_{growth}, 0.05, 0.95) ;$$

$$vol_budget = v_min + risk_fraction \cdot (v_max - v_min)$$

股息傾斜強度（高成長需求降低 τ ，高收益需求增加 τ ）：

$$\tau = 0.30 \cdot (1 - T_{growth}) \cdot R, \quad R = clip(w_{CAGR} + w_{Div}, 0, 1)$$

此設計的數學意涵： $g(w)$ 是從 9 維偏好空間到最佳化參數空間的連續滿射，確保任意中間偏好均能平滑對應至效率前沿的正確位置，避免離散查表的邊界跳躍問題。

附錄 B：完整技術堆疊

層次	工具 / 套件	用途說明
資料擷取	yfinance (YahooQuery), alpha_vantage, finnhub-python	多源 ETF 價格、基本面、新聞情緒數據
NLP 情緒分析	FinBERT (本地部署), transformers	財經新聞情緒分類，時間衰減加權
語義嵌入	BGE-M3 (BAAI)	自然語言偏好描述轉換為語義向量
LLM 整合	Google Gemini API	Active Bayesian 路徑的自然語言訪談代理
效率分析	scipy.optimize (線性規劃)	DEA CCR 模型與交互效率矩陣求解
組合最佳化	scipy.optimize.minimize (SLSQP)	帶約束投資組合二次規劃求解
共變異數估計	sklearn.covariance.LedoitWolf	穩健共變異數矩陣縮減
貝氏神經網路	PyTorch + Pyro (10 模型集成)	偏好引擎不確定性估計
AHP 求解	numpy (特徵值分解)	成對比較矩陣優先向量計算
Web 後端	Flask + threading	偏好問卷 API、管線異步執行、結果服務
資料視覺化	matplotlib, plotly (前端 JS)	雷達圖、績效走勢、效率前沿散點圖
部署環境	Python 3.11, pip, .env 環境變數	本地執行；Docker 容器化為待辦項目

表 3.6 本系統係數摘要

附錄 C：系統檔案結構

OptETF 專案完整模組結構（依 GitHub 實際目錄）：

```
FinTech-Project-FinalVersion/
├── main.py                # 系統入口，preference_mode 切換
├── pipeline_stages.py     # 五階段管線調度器
├── functions.py          # 核心算法：DEA / BL / SLSQP / g(w)
├── parameters.py         # 全域參數配置 (TOP_N ETFs=500, etc.)
├── backtest_engine.py    # Walk-Forward 回測引擎
├── AHP_weights_setting_script.py # AHP 問卷腳本
├── requirements.txt      # 基本依賴套件
├── requirements-active_preference.txt # LLM 路徑額外依賴
├──
├── active_preference/    # Active Bayesian LLM 訪談模組
├── etf_preference_bundle/ # BNN 偏好引擎 (10 個 .pt 模型)
│   ├── *.pt             # 預訓練 BNN 模型權重
│   ├── canonical_questions/ # 標準化問題池
│   └── config/           # 校準參數
├── etf_web/              # Web 前端應用
│   ├── app.py           # Flask 主應用 (路由、API、管線啟動)
│   ├── templates/       # HTML 模板
│   └── static/           # JS / CSS 前端資源
├── sentiment_engine/     # FinBERT 情緒分析管線
├── local_finbert/       # 本地 FinBERT 模型檔案
├──
├── csv/                 # 各 Stage 輸出矩陣 (.csv)
├── json/                # ETF 資料庫 (etf_database.json, 212 KB)
├──
├── user_results/        # 七種使用者原型完整分析結果
├── experiments/         # 15+ 研究實驗腳本
├── system_upgrade_records/ # 系統演進記錄 (10 份 .md)
├──
├── ARCHITECTURE.md      # 架構說明文件
├── REPORT_A_results_and_math.md # 數學細節與回測佐證
└── REPORT_B_design_story.md # 設計決策背景
```

附錄 D：小組分工與簽名

小組成員	分工	簽名
110011131 蔡妮軒	網頁架構、書面報告撰寫	
111034010 羅彥凱	系統程式架構、最佳化方法設計	
111034058 林昱佑	資料彙整與流程設計、簡報製作	
114071507 張立妍	主題發想與痛點分析、文獻蒐集	